# Yassine Ben Kacem

Élève ingénieur en dernière année de génie logiciel — Systèmes d'IA agentique sécurisés et de génération augmentée par la recherche (RAG)
yacinbenkacem19@gmail.com | linkedin.com/in/yassine-ben-kacem | github.com/YACINBK | yacinbenkacem.me | +216 29 504 806

## PROFIL

Élève ingénieur en dernière année de génie logiciel à l'ENISO, spécialisé en IA agentique et en génération augmentée par la recherche (RAG) : développement d'agents IA qui appellent des outils, agissent de façon autonome et vérifient leurs propres résultats avant de les transmettre à l'utilisateur. Intégration du contrôle d'accès par rôles (RBAC) et de l'authentification OAuth 2.0 / OpenID Connect (OIDC) directement dans les parcours de recherche et d'exécution des agents, plutôt qu'a posteriori ; conception des couches de fidélité aux sources et de vérification assurant l'auditabilité des systèmes multi-agents et RAG en production.

## EXPÉRIENCE PROFESSIONNELLE

**Stagiaire en IA et automatisation** — **Juin 2026 – Août 2026**
*White Cape Technologies* — *Sousse, Tunisie*

**Assistant de connaissances RAG agentique avec prise en compte des rôles**

- Développement d'un assistant IA interne permettant aux équipes d'ingénierie d'interroger les connaissances et bases de code de l'entreprise en langage naturel, sans recherche manuelle — machine à états LangGraph de 9 nœuds (classification → recherche → reclassement → filtre de pertinence → génération → vérification de fidélité aux sources), fournissant des réponses étayées, citées et adaptées au rôle, diffusées en direct via Server-Sent Events (SSE).
- Contrôle des accès par rôle et privilèges d'administration dans la requête de recherche, plutôt que l'interface : exclusion des passages non autorisés dès la recherche, sans filtrage ultérieur — aucune violation d'autorisation sur 280 recherches auditées ; contenus de rémunération restreints inaccessibles aux non-administrateurs, mais exploitables par les administrateurs, avec authentification de session Keycloak OpenID Connect (OIDC) et protection contre la falsification de requêtes intersites (CSRF).
- Création d'une suite d'évaluation de la recherche sur données annotées (jeux de test réservés, scores hors ligne reproductibles) pour fixer le seuil de pertinence sur des mesures : 23 cas trompeusement proches conçus à cet effet ont écarté un seuil acceptant 12 questions sans réponse sur 29. Seuil fixé à 0,5, où l'exactitude équilibrée est maximale, divisant par deux les réponses indûment fournies, à 6 sur 29.
- Diagnostic d'une faiblesse de vérification en soumettant une affirmation inventée au contrôle de fidélité : score parfait de 1,000, identique au témoin étayé, démontrant que le recouvrement lexical ne distingue pas les affirmations fondées des inventions. Livraison de cette sonde sous forme de test de régression reproductible pour valider en quelques secondes tout remplacement fondé sur l'implication sémantique.
- Réduction de 46 % du contexte récupéré par requête après exploration de six seuils de filtrage : choix de 0,025, maximisant la réduction tout en maintenant le rappel des preuves directes à 1,000.
- Suppression d'un point unique de défaillance dans l'ingestion documentaire — environ 472 appels séquentiels au modèle par document, un seul échec annulant toute l'exécution — par un mécanisme de reprise à trois tentatives et délai exponentiel dans l'unique couche de transport LLM. Liste d'exceptions autorisées excluant le signal de délai souple de Celery, afin qu'une tâche hors délai puisse encore enregistrer son propre échec.
- Exécution d'une pile d'inférence entièrement locale (LiteLLM → Ollama, Qdrant, embeddings BGE-M3, bge-reranker-v2-m3 via Hugging Face TEI), conservant tous les contenus documentaires propriétaires sur le réseau interne pour répondre aux exigences de conformité.
- Développement du système par une boucle IA à trois rôles (planificateur, générateur, évaluateur), sur 45 modules pilotés par contrats et 415 tests. Vérification de chaque correction par des tests de mutation, prouvant que chaque garde-fou est mis en défaut lorsque son défaut est réintroduit.

  **Technologies :** LangGraph, FastAPI, LiteLLM, Ollama, Qdrant, BGE-M3, Keycloak, OIDC, Celery, Redis, pytest, Python, évaluation de la recherche

**Stagiaire en IA et automatisation** — **Juin 2025 – Août 2025**
*White Cape Technologies* — *Sousse, Tunisie*

**UX Insight Platform**

- Développement d'une plateforme d'audit de l'expérience utilisateur (UX) par IA, évaluant automatiquement les interfaces web et applicatives à partir de captures d'écran brutes et de données d'interaction, pour fournir aux équipes produit des rapports UX structurés et étayés, sans analyse manuelle.
- Création d'une couche de vision par ordinateur détectant et classant les éléments d'interface directement dans les captures d'écran, afin de fournir à la plateforme une structure exploitable pour le raisonnement plutôt que des pixels bruts.
- Combinaison des détections, de l'extraction de texte par reconnaissance optique de caractères (OCR) et de la télémétrie d'interaction pour produire des constats UX structurés et exploitables par les équipes produit, plutôt que des captures à interpréter manuellement.
- Ancrage des analyses générées dans une couche RAG fondée sur ChromaDB, recherchant les heuristiques UX pertinentes et les constats antérieurs avant génération, pour produire des rapports professionnels de niveau consultant plutôt que des sorties LLM génériques.
- Indépendance de la couche LLM vis-à-vis des fournisseurs grâce au routage entre OpenAI, Mistral, DeepSeek, OpenRouter et les modèles locaux Ollama, pour maintenir le service si un fournisseur devient indisponible ou trop coûteux.
- Déport des traitements IA lourds hors du parcours des requêtes vers des tâches asynchrones avec file d'attente, interrogation périodique et reprise ; sécurisation de la passerelle par Keycloak OAuth 2.0 / OIDC et validation des JSON Web Tokens (JWT).
- Isolation de l'inférence LLM, de l'OCR et du traitement d'images dans des microservices FastAPI dotés de mécanismes de repli derrière la passerelle, avec PostgreSQL, cache Redis et Docker Compose.

  **Technologies :** Angular, Spring Boot, FastAPI, ChromaDB, Keycloak, JWT, PostgreSQL, Redis, Docker Compose

## PROJETS

**Chaîne agentique de production vidéo** — **2026**

- Développement d'une chaîne agentique de production vidéo autonome de bout en bout, inspectant le système de fichiers avant

chaque étape pour ignorer les traitements déjà terminés au lieu de tout recommencer.
- Conception d'une boucle de génération autocorrective détectant les sorties rejetées ou mal formées, reformulant automatiquement le prompt et relançant la génération au lieu de faire échouer l'exécution.
- Reprise de la chaîne après interruption au point d'arrêt, sans redémarrage complet.
- Renforcement de l'automatisation navigateur avec des sélecteurs Playwright de repli et des relances, pour résister aux changements d'interface des sites automatisés.

**Technologies :** Python, Playwright, FFmpeg, Whisper, synthèse vocale avec clonage de voix (TTS)

**Chaîne de développement multi-agents MCP** **2026**

- Création de serveurs Model Context Protocol (MCP) exposant les outils de mes projets dans Claude Code, permettant aux agents d'appeler des fonctions et d'agir directement sur les fichiers réels des projets.
- Conception d'une chaîne de développement multi-agents aux rôles distincts de planificateur, générateur et évaluateur, produisant et vérifiant le code par des tests de contrat plutôt que par la seule revue manuelle des différences.
- Utilisation quotidienne active dans mon propre processus de développement.

**Technologies :** MCP, Claude Code, Python

**Chaîne de vectorisation d'images par IA** **2025**

- Conception en Python d'une chaîne de génération d'images par IA et de vectorisation pour la création de vêtements, sous contrainte de 8 Go de mémoire vidéo (VRAM).
- Automatisation du prétraitement, de la segmentation par Segment Anything Model (SAM), de la simplification des couleurs Oklab et du traçage Scalable Vector Graphics (SVG), pour des résultats reproductibles prêts à l'emploi en vectoriel.
- Isolation de chaque étape dans un sous-processus, avec libération explicite de la VRAM entre les étapes pour stabiliser l'exécution sur du matériel grand public et éviter la fragmentation liée à un processus unique de longue durée.
- Ajout de points de reprise par lot : après un plantage ou une interruption, le traitement reprend à la dernière image terminée plutôt qu'au début.

**Technologies :** Python, Segment Anything (SAM), VTracer, OpenCV, Pillow

**QuickFlow — Assistant de productivité IA** **2025**

- Création d'un assistant IA de productivité full-stack avec Spring AI et Spring Boot en backend : synthèses automatiques de réunions, comptes rendus structurés et brouillons d'e-mails professionnels à partir des données brutes des réunions.
- Prise en charge de la branche identité et sécurité : configuration de Keycloak OIDC avec fédération d'identité Google et Microsoft et authentification multifacteur par mot de passe à usage unique fondé sur le temps (TOTP/MFA), pour une authentification sécurisée, compatible avec la connexion par comptes tiers et commune aux parcours de toute l'équipe.
- Développement des parcours frontend Angular en séparant l'état d'authentification du travail en cours, afin qu'un renouvellement de session ne fasse jamais perdre un brouillon non enregistré.
- Conception de flux réutilisables d'automatisation des communications : conversion synthèse-vers-e-mail modélisée dans un composant réutilisé par l'équipe dans trois fonctionnalités, sans réécriture.

**Technologies :** Spring Boot, Spring AI, Angular, Keycloak, OIDC, JWT, TOTP, MFA

## COMPÉTENCES

**IA agentique et orchestration de LLM :** LangGraph, LangChain, Model Context Protocol (MCP), orchestration multi-agents, appels d'outils et actions autonomes, génération augmentée par la recherche (RAG), Graph-RAG, LiteLLM, déploiement local de LLM (Ollama), reclassement (TEI), cache sémantique, contrôles de fidélité aux sources et de vérification, observabilité des agents et journaux d'audit, optimisation de l'inférence LLM,
ingénierie des prompts et du contexte
**Sécurité de l'IA et contrôle d'accès :** OAuth 2.0 / OpenID Connect (OIDC), contrôle d'accès par rôles (RBAC), validation JWT, Keycloak, fédération d'identité (Google/Microsoft), authentification multifacteur (TOTP/MFA), sécurité IA/ML (robustesse adversariale, défenses contre l'empoisonnement RAG, détection de vulnérabilités)
**Backend et données :** FastAPI, Spring Boot, PostgreSQL, Redis, Qdrant, bases de données vectorielles, ChromaDB, Celery, Server-Sent Events (SSE), architecture microservices
**DevOps et ingénierie de production :** Docker et Docker Compose, Git/GitHub/GitLab, CLI Linux, tests automatisés pilotés par contrats
**IA générative et vision par ordinateur :** Modèles de diffusion (FLUX), Segment Anything (SAM), OCR, YOLO
**Langages de programmation :** Python, Java, JavaScript/TypeScript, SQL, C, C++

## CERTIFICATIONS

**NVIDIA Deep Learning Institute (DLI):** Building RAG Agents with LLMs · Building Transformer-Based NLP Applications · AI Cybersecurity Pipelines · Building LLM Applications With Prompt Engineering
Fundamentals of Deep Learning · Generative AI with Diffusion Models · Building Real-Time Video AI Applications · Applications of AI for Predictive Maintenance
**DeepLearning.AI:** Neural Networks and Deep Learning · Supervised Machine Learning
**Google Cloud:** Introduction to Generative AI
**Compétition :** IndabaX Tunisia 2025 Challenge 1 — parmi les 50 % premiers (31/69), hackathon de 20 heures d'apprentissage automatique appliqué à la détection d'anomalies des indicateurs clés de performance (KPI) télécoms 4G/5G

## FORMATION

**École Nationale d'Ingénieurs de Sousse (ENISO)** **Sept. 2024 – En cours**
Diplôme d'ingénieur en génie logiciel

**Institut préparatoire aux études d'ingénieurs de Monastir** **Sept. 2022 – Juin 2024**
Cycle préparatoire mathématiques et physique — Rang national : 509 / 1800

## LANGUES

**Arabe :** Langue maternelle **Anglais :** Courant **Français :** Courant **Allemand : A1**